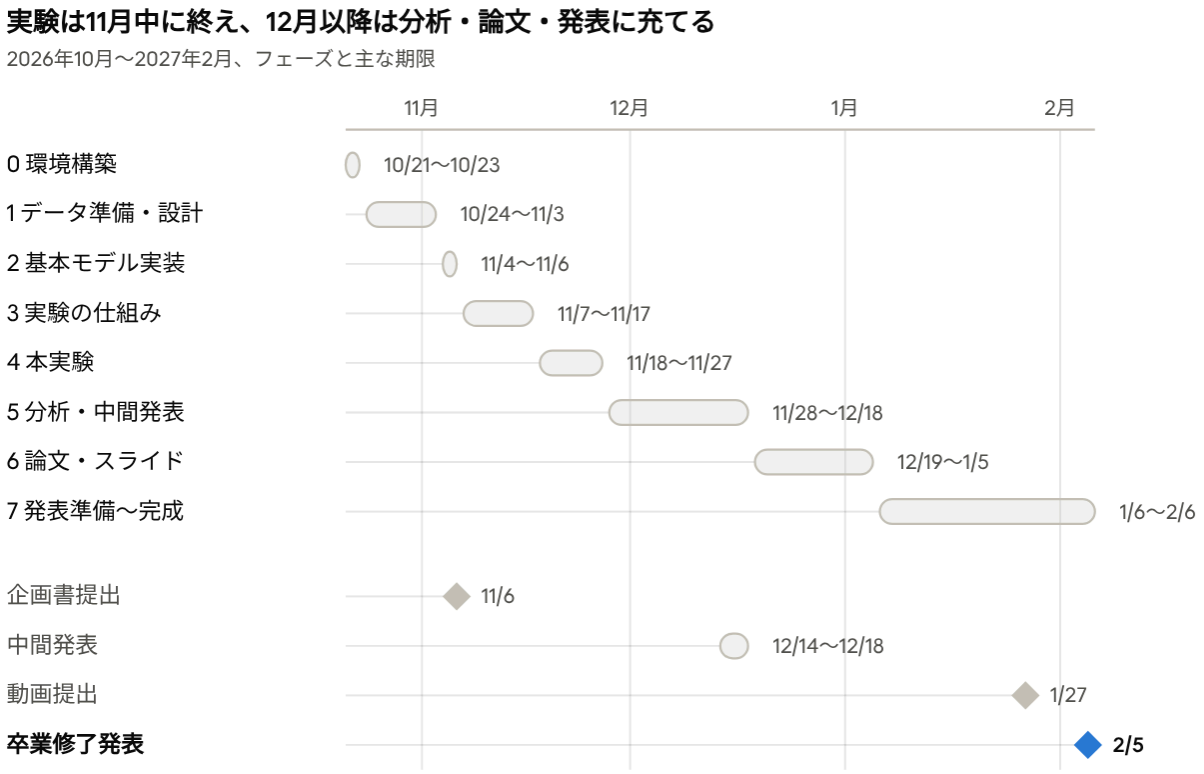
卒業研究ロードマップ（環境構築〜完成）

Oct 21, 2026 · @Lil

全体像

環境構築（10/21〜）から卒業修了発表（2/5）・作品展（2/6）まで、8つのフェーズで進めます。実験は11/27までに終え、12月以降を分析・論文・発表準備に充てます。日程は企画書Excelの工程表と卒業研究説明書に合わせています。



卒業研究の工程·8フェーズと4つの期限

各フェーズの最後に「完了条件」を置き、関門①〜④と最終関門を越えたら次へ進みます。

フェーズ0　環境構築（10/21〜10/23）

10/23（金）までに「どのPCでも同じ手順で実験が動く状態」を作ります。工程表では「進行中」の項目です。

1. Python 3.11 または 3.12 をインストールする（python.org版。インストール時に「Add python.exe to PATH」にチェック）。`python --version` で確認する
2. VS Code に拡張機能「Python」「Jupyter」を入れる
3. 研究用フォルダを作る

- `graduation\research\` の下に `data/`（元データ）、`src/`（プログラム）、`results/`（CSV）、`figures/`（グラフ）、`notebooks/`（試し書き）、`docs/`（論文・スライド）

4. 仮想環境を作り、ライブラリを入れる
   - `python -m venv .venv` → `.venv\Scripts\activate`
   - `pip install pandas numpy scikit-learn matplotlib seaborn ucimlrepo`
   - `pip freeze > requirements.txt`（論文の「実験環境」にバージョンを書くため）
5. グラフの日本語文字化け対策として、Matplotlibのフォントを `Yu Gothic` か `MS Gothic` に設定する
6. Git でバージョン管理を始める（推奨）。`.gitignore` に `.venv/` と `data/` を入れる
7. `src/check_env.py` を作り、各ライブラリのバージョン表示と、irisデータでの小さな学習が動くことを確認する

完了条件：`check_env.py` がエラーなく動き、`requirements.txt` が保存されている。

フェーズ1　データ準備・実験設計（10/24〜11/3）

11/3（火）までに「何を変えて、何を固定し、何で測るか」を文書で確定させます。ここが曖昧なまま実装に入ると、後で実験をやり直すことになります。

データセットを決める（〜10/27）

1. 候補は UCI の Bank Marketing（id=222）と Adult（id=2）。どちらも2クラス分類で、元から少数クラスがある
2. `ucimlrepo` で読み込み、件数・特徴量・欠損値・クラスごとの件数を `notebooks/01_eda.ipynb` に記録する
3. 決め手は「少数クラスの件数」。学習用の少数クラス件数が、最大データ量 × 50% を上回っている必要がある（例：5,000件・均衡なら2,500件）
4. Bank Marketing を使う場合、`duration`（通話時間）は結果が分かった後の情報なので特徴量から外す（UCIの説明にも記載あり）

実験条件・評価指標を決める（〜10/30）

項目	案
変える条件① 学習データ量	500 / 1,000 / 2,000 / 5,000 件
変える条件② 少数クラス比率	50% / 30% / 10% / 5% / 1%
繰り返し	乱数シードを5通りに変えて平均と標準偏差

項目	案
評価指標	Accuracy、少数クラスの Precision・Recall・F1、PR-AUC
固定するもの	テストデータ（元の比率のまま）、前処理、ハイパーパラメータ

実行回数は 2モデル × 4データ量 × 5比率 × 5シード = 200回。小さな表形式データなので、普通のノートPCでも数分〜数十分で終わる見込みです。

モデルと実験手順を決める（〜11/3）

1. モデルはロジスティック回帰とランダムフォレスト（線形モデルと木モデルで性質が異なるため比較しやすい）
2. 決めた内容を `docs/experiment_design.md` に1ページでまとめ、先生に確認してもらう

完了条件（関門①）：実験計画書があり、先生の確認を得ている。

フェーズ2　基本モデルの実装（11/4〜11/6）

11/6（金）までに、全データで1回学習・評価できる「基準ライン」を作ります。同日は企画書の正式提出期限（17:00、Teams「01_企画書提出用」）でもあります。

1. `src/data.py`：データの読み込みと前処理（不要列の削除、欠損値処理、ラベルを0/1に変換）
2. 学習用・テスト用に分ける（`test_size=0.3`、`stratify=y`、`random_state=42`）。テストデータはここで固定し、以後触らない
3. `src/models.py`：カテゴリ列は OneHotEncoder、数値列は StandardScaler を ColumnTransformer にまとめ、2モデルと Pipeline でつなぐ
4. `src/baseline.py`：全データで学習し、`classification_report` を表示する

完了条件：2モデルの基準スコアが出て、数値をメモしている（本実験の比較対象になる）。

フェーズ3　実験の仕組みを作る（11/7〜11/17）

11/17（火）までに、コマンド1つで全条件の実験が回り、CSVが出る状態にします。

1. **データ量・比率を変える関数（〜11/10）**：`make_subset(X, y, n_total, minority_ratio, seed)` を作り、作れない条件はスキップする。各条件で実際の件数・比率をprintして確かめる
2. **評価とCSV保存（〜11/13）**：`evaluate()` で指標を辞書で返し、1行＝1回の実験として `model, n_train, ratio, seed, accuracy, precision, recall, f1, pr_auc` を保存する

3. **複数モデルの実験ループ（〜11/17）**：`src/run_experiment.py` にモデル × データ量 × 比率 × シードのループを書く。条件の値はファイル先頭の設定にまとめる
4. **お試し実行**：条件を絞った `--quick` モード（1分以内）を用意し、行数と中身が正しいか確かめる。このモードは発表の「実機説明」でも使う

完了条件（関門②）：`--quick` のCSVが想定どおりの行数・列で出力される。

フェーズ4　本実験（11/18〜11/27）

11/27（金）までに全条件の結果をCSVで揃えます。実行自体は短時間ですが、やり直しに備えて余裕を持たせています。

1. 本実験を実行し、`results/results_日付.csv` として保存する（上書きしない）
2. 実行日時・条件・ライブラリのバージョンを `docs/experiment_log.md` に記録する
3. 異常値チェック：スキップされた条件、Recallが0ばかりの条件がないか確認する
4. 結果のバックアップを取る（OneDrive など）
5. 時間が余ったら拡張実験：`class_weight='balanced'` を付けた場合との比較（不均衡への対策として考察が深まる）

完了条件（関門③）：全条件分の行があるCSVと実験ログがそろっている。

フェーズ5　分析・中間発表（11/28〜12/18）

12/11（金）までにグラフと考察のメモを作り、そのまま中間発表（12/14〜18）に使います。

1. **集計とグラフ（〜12/4）**：`src/analyze.py` を作る
   - groupby で条件ごとの平均・標準偏差を求め、`results/summary.csv` に保存
   - 折れ線グラフ：横軸＝少数クラス比率、縦軸＝Recall・F1、線＝データ量（モデルごと）
   - ヒートマップ：データ量 × 比率のF1（Seaborn、モデルごと）
   - Accuracy と Recall を並べたグラフ（「Accuracyは高いのに少数クラスを外す」現象を見せる）
   - すべて `figures/` にPNGで保存し、論文とスライドで使い回す
2. **分析・考察（〜12/11）**：次の問いにそれぞれ数値で答える
   - データ量が増えると少数クラスのRecall・F1はどう変わるか
   - 不均衡が強いとき、AccuracyとRecallはどれだけ食い違うか
   - データ量と不均衡、影響が大きいのはどちらか
   - 2モデルで不均衡への強さは違うか
   - 少数クラスを適切に予測できるデータ量・比率の目安はどこか

3. **中間発表（12/14〜18）**：企画内容／予定と実績（`--quick` の実機説明を含む）／今後の予定／課題をPowerPointにまとめて発表し、Teams「02_PowerPoint資料提出用」に保存する

完了条件（関門④）：中間発表を終え、先生からの指摘をメモしている。

フェーズ6　論文・スライド（12/19〜1/5）

12/28（月）に論文の初稿、1/5（火）に発表スライドを仕上げます。冬休みを挟むので、休み前に章立てだけは必ず作っておきます。

1. 中間発表の指摘を反映し、必要なら追加実験をする（12/19〜12/22）
2. 論文の章立て：はじめに → 関連知識（クラス不均衡、評価指標）→ 実験方法 → 結果 → 考察 → まとめ・今後の課題
3. 「実験方法」「結果」は実験計画書・実験ログ・`figures/` から先に書く（一番書きやすい）
4. 論文初稿を仕上げ、先生に見てもらう（〜12/28）
5. 発表スライドを作る（〜1/5）：10分以内で「背景 → 方法 → 結果グラフ → 実機説明 → まとめ」。結果はグラフ2〜3枚に絞る

完了条件：論文初稿とスライドがそろっている。

フェーズ7　発表準備から完成まで（1/6〜2/6）

2/5（金）の卒業修了発表と2/6（土）の作品展がゴールです。どちらも卒業基準なので、提出物は期限の前日までに終えます。

1. 発表原稿と想定質問を用意し、練習する（〜1/14）
   - 想定質問の例：なぜAccuracyではなくF1を重視したのか／なぜこの2モデルか／テストデータを固定した理由／実務ではどう活かせるか
2. 論文・スライド・コードを最終確認する（〜1/19）。`README.md` に実行手順を書き、新しい環境で `requirements.txt` から動くか確かめる
3. 発表練習（説明書で1/12〜15、工程表で1/18〜22と日程が異なるので先生に確認）
4. 動画撮影（1/18〜22）：表紙（チーム名・学科名・学年・氏名・タイトル）→ 自己紹介 → PPT → 実機説明 → 感想、5〜10分、mp4
5. 動画をTeams「03_動画提出用」に提出（1/27（水）17:00まで）
6. 発表リハーサル（2/3）：会場のPC・プロジェクターで `--quick` が動くか、動かない場合の録画を用意したか確認
7. 卒業修了発表（2/5）、作品展（2/6）。作品一式（コード・結果CSV・グラフ・論文）をTeams「04_作品提出用」に保存

完了条件（最終関門）：発表と展示を終え、すべての提出フォルダに保存済み。

週ごとの予定

企画書Excel「３．報告書」の週番号に合わせています。週末の報告書は「その週の成果物」列ができたかどうかで書くと楽です。

週	期間	フェーズ	その週の成果物
1	10/19〜10/25	0 環境構築	`check_env.py` が動く、`requirements.txt`
2	10/26〜11/1	1 設計	データ確認ノート、実験条件表、フォーム申請（10/30）
3	11/2〜11/8	1・2	実験計画書、基準スコア、企画書の正式提出（11/6）
4	11/9〜11/15	3 実験の仕組み	`make_subset`、`evaluate`、CSV保存
5	11/16〜11/22	3・4	`run_experiment.py`（`--quick` 付き）、本実験開始
6	11/23〜11/29	4 本実験	結果CSV、実験ログ
7	11/30〜12/6	5 分析	`summary.csv`、グラフ一式
8	12/7〜12/13	5 分析	考察メモ、中間発表スライド
9	12/14〜12/20	5・6	中間発表、指摘メモ、論文の章立て
冬休み	12/21〜1/10	6 論文	論文初稿（12/28）、スライド（1/5）
10	1/11〜1/17	7 発表準備	発表原稿、想定質問集
11	1/18〜1/24	7	最終版一式（1/19）、動画撮影
12	1/25〜1/31	7	動画提出（1/27 17:00）
13	2/1〜2/6	7	リハーサル（2/3）、発表（2/5）、展示（2/6）

報告書シートの10週目以降は日付が2026年になっているため、2027年に直してください。

リスクと完成チェックリスト

遅れが出やすいのは「設計のやり直し」と「冬休み中の論文」です。先に手を打っておきます。

リスク	対策
少数クラスが足りず「5,000件・50%」などが作れない	10/27の時点で件数を計算し、作れない条件は設計段階で外す
不均衡1%でRecallが全部0になり、差が見えない	PR-AUCも併記する。「0になること」自体を結果として考察に使う
実験のやり直しで結果が混ざる	CSVに日付を付け、実験ログとGitでどのコードの結果か分かるようにする
冬休みで論文が止まる	休み前に章立てと「方法」「結果」を書き始めておく
発表当日にPC・環境が動かない	`--quick` の実行画面を録画しておき、スライドにも入れる

完成の定義（企画書の研究のゴール1〜5）

- [ ] データ量とクラス比率を変えて実験できるプログラムが完成している
- [ ] 2種類のモデルで、複数条件の性能を比較できる
- [ ] 結果がCSVに保存され、評価指標がグラフ化されている
- [ ] 少数クラスのRecall・F1を中心に、データ量と不均衡の影響を分析している
- [ ] 論文、発表スライド、実験コード（README付き）がそろっている

提出物

- [ ] メンバー申請・研究内容申請（10/30）
- [ ] 企画書・工程表を「01_企画書提出用」へ（11/6 17:00）
- [ ] 中間発表資料を「02_PowerPoint資料提出用」へ（12/14〜18）
- [ ] 発表動画を「03_動画提出用」へ（1/27 17:00）
- [ ] 作品一式を「04_作品提出用」へ（2/5まで）
- [ ] 報告書を毎週末に記入